VERİ BİLİMİ & MAKİNE ÖĞRENMESİ ANA YOL HARİTASI

Her Veri Setine Uygulanabilir 6 Aşamalı Metodoloji, EDA Protokolü, Model Seçimi ve Metrikler

BÖLÜM 1: Uçtan Uca Problem Çözme Döngüsü (CRISP-DM Standardı)

Adım 1: İş Hedefini ve Problemin Tanımını Netleştirmek

• Nihai Amaç: Model kime hizmet edecek? (Müşteri terkini önleme, sepet büyütme, fiyat tahmini vb.)
• Problem Türü: Regresyon (sayı tahmini) mı, Sınıflandırma (etiket tahmini) mı, Kümeleme (segmentasyon) mi?
• İş Maliyeti: Yanlış tahminin şirkete maliyeti nedir? (Örn: Dolandırıcılığı kaçırmak vs masum kartı bloke etmek).

Adım 2: Veri Kaynaklarını Belirlemek, Toplamak ve Keşfetmek (Standart 4 Aşamalı EDA Protokolü)

Herhangi bir veri seti önüne geldiğinde standart EDA protokolü şu 4 adımdır:
• 1. Boyut ve Tipler (Shape & Info): Kaç satır, kaç sütun var? Sayısal mı, metin mi, tarih mi?
• 2. Veri Hijyeni (Missing Values & Outliers):
  - Eksik veri (NaN) var mı? Varsa neden eksik? (Sistem hatası mı, yoksa mantıksal bir eksiklik mi? Örn: İlk siparişte geçen gün sayısı boştur).
  - Aykırı değer (Outlier) var mı? (Örn: Bir sepette 5.000 adet ürün olması gibi).
• 3. Hedef Değişkenin Dağılımı (Target Distribution): Sınıflar dengeli mi, dengesiz mi? (Dengesizse model çoğunluğa yatıp bizi kandırabilir).
• 4. Değişkenler Arası İlişkiler (Korelasyon ve Davranışlar): Müşteriler en çok hangi saatlerde alışveriş yapıyor? Hangi ürünler birlikte alınıyor? En çok tekrar sipariş edilen reyonlar hangileri?

Adım 3: Özellik Mühendisliği (Feature Engineering) & Veri Sızıntısı (Leakage) Güvenliği

• Yeni Değişken Türetme: Oranlar, farklar, RFM skorları (Recency, Frequency, Monetary), tarih/zaman bileşenleri.
• Encoding: Nominal için One-Hot, sıralı için Ordinal, yüksek kardinalite için Target/Frequency Encoding.
• Veri Sızıntısı (Data Leakage) Kilidi: Tahmin anında bilinmeyecek hiçbir sütunu eğitime katma! Fit işlemini (Scaler/Encoder) sadece train setine uygula!

Adım 4: Model Seçimi, Geliştirme ve Validasyon Mimarisi

• Baseline (Referans) Şartı: Karmaşık modele geçmeden önce her zaman basit bir kural/Lojistik Regresyon kur.
• Validasyon Stratejisi: Zaman serisinde Time-based Split; dengesiz veride Stratified K-Fold CV.
• Hiperparametre Optimizasyonu: GridSearch yerine rastgele (Random Search) veya Bayesyen (Optuna).

Adım 5: Başarı Metriklerinin Seçilmesi (İş Hedefine Göre Doğru Terazi)

• Dengesiz Veride Accuracy Tuzağı: F1-Score, Precision, Recall, PR-AUC ve Karışıklık Matrisi kullan.
• İş KPI Eşleştirmesi: Modelin teknik skoru işletmenin kârına/dönüşüm oranına nasıl yansıyor?

Adım 6: Hata Analizi (Error Analysis), İterasyon ve Canlı İzleme (MLOps)

• Hataların Röntgeni: Model hangi alt grupta yanılıyor? Hatalardan yeni öznitelik çıkar.
• Model & Data Drift: Canlıya alınan modelin zamanla performans kaybını izleme (Monitoring).

BÖLÜM 2: Model Seçim Karar Ağacı (Hangi Durumda Hangi Algoritma?)

Veri Tipi ve Problem Durumu	Önerilen Model	Neden Seçilir? / Ne Zaman Tercih Edilir?
Küçük Veri / Tablo (< 5.000 satır, basit ilişki)	Lojistik Regresyon / Ridge / Lasso	Aşırı ezberlemez (düşük varyans), hızlıdır, katsayıları doğrudan açıklanabilir.
Orta - Büyük Tablo Verisi (10.000 - 10.000.000 satır)	**LightGBM, XGBoost, CatBoost**	Sektörün tartışmasız şampiyonu. Karmaşık ve non-lineer ilişkileri, eksik veriyi en iyi çözer.
Hızlı Prototip / Kararlı Ağaç (Hiperparametreyle az uğraşma)	Random Forest	Paralel çalışır, ayar yapmadan iyi sonuç verir, varyansı (overfitting) düşürmede başarılıdır.
Metin / Doğal Dil İşleme (NLP) (Yorumlar, destek mesajları)	BERT, RoBERTa, LLM (Transformer)	Kelimelerin bağlamını ve iki yönlü anlam ilişkilerini yakalayabilen tek mimari.
Görüntü ve Video (Vision) (Kusur tespiti, yüz tanıma)	CNN (VGG, ResNet, EfficientNet)	Piksel pikseller arası uzamsal dokuları ve kenarları konvolüsyon filtreleriyle çıkarır.
Zaman Serisi / Sıralı Sensör (Borsa, enerji tüketimi)	Prophet, ARIMA, LSTM, Temporal Fusion	Mevsimsellik, trend ve geçmiş zaman adımlarındaki bağımlılıkları modeller.
Etiketsiz Veri / Kümeleme (Müşteri segmentasyonu)	K-Means, DBSCAN, PCA	Hedef değişken (Y) olmadığında veriyi benzerliklerine göre gruplar veya boyut indirger.

BÖLÜM 3: Başarı Metrikleri Rehberi (Hangi Metrik Ne Zaman Kullanılır?)

Problem Türü	Metrik Adı	Ne Anlama Gelir? / Ne Zaman Bakılır?
Dengesiz Sınıflandırma (Fraud, Hastalık, Kusur)	**Precision (Kesinlik)**	Model pozitif dediklerinin kaçı gerçekten doğru? Sahte alarmları (False Positive) kısmak gerektiğinde (Örn: Spam filtresi).
Dengesiz Sınıflandırma (Fraud, Hastalık, Kusur)	**Recall (Duyarlılık)**	Gerçek pozitiflerin kaçı yakalandı? Kaçırma riskinin maliyeti yüksek olduğunda (Örn: Kanser teşhisi, Kaçak işlem).
Dengesiz Sınıflandırma	**F1-Score / PR-AUC**	Precision ve Recall dengesidir (harmonik ortalama). Sınıf dengesizliğinde genel karne metriğidir.
Dengeli Sınıflandırma	Accuracy (Doğruluk)	Tüm sınıflar eşit sayıda örnek içeriyorsa güvenle kullanılır (Sınıflar dengesizse KULLANILMAZ!).
Regresyon (Sayı Tahmini) (Fiyat, Sıcaklık, Süre)	MAE (Ortalama Mutlak Hata)	Aykırı değerlerin cezalandırılmasını istemiyorsan, ortalama sapmayı orijinal birimle verir (TL, cm).
Regresyon (Sayı Tahmini)	RMSE / MSE	Büyük hataları kareleriyle cezalandırır. Aykırı değerlerin affedilmediği durumlarda tercih edilir.
Regresyon (Sayı Tahmini)	R^2 Skoru (Determinasyon)	Modelin verideki varyansın yüzde kaçını açıkladığını gösterir (1.0 = mükemmel model).
Öneri & Sıralama (Ranking) (E-Ticaret, Market Sepeti)	**MAP@K / Top-K Accuracy**	Kullanıcıya önerilen ilk K üründen kaçı sepetine girdi? Sıralama doğruluğunu ölçer.